TRƯỜNG ĐẠI HỌC QUẢN LÝ VÀ CÔNG NGHỆ
THÀNH PHỐ HỒ CHÍ MINH

KHOA CÔNG NGHỆ

KHÓA LUẬN TỐT NGHIỆP

DỰ ĐOÁN Ý ĐỊNH VÀ PHÁT HIỆN SỚM HÀNH VI CHUYỂN LÀN CẮT MẶT CỦA PHƯƠNG TIỆN THAM GIA GIAO THÔNG TỪ DỮ LIỆU CAMERA HÀNH TRÌNH

Họ và tên sinh viên 1	: PHẠM PHƯỚC MINH HIẾU
Mã số sinh viên	: 2201700085
Họ và tên sinh viên 2	: CAO SỸ SIÊU
Mã số sinh viên	: 2201700170
Ngành đào tạo	: CÔNG NGHỆ THÔNG TIN
Khóa	: K2022
Giảng viên hướng dẫn	: ThS. Huỳnh Lê Phú Trung

Thành phố Hồ Chí Minh, tháng . . . năm 2026

LỜI CAM ĐOAN

Chúng tôi xin cam đoan đồ án tốt nghiệp với đề tài "Dự đoán ý định và phát hiện sớm hành vi chuyển làn cắt mặt của phương tiện tham gia giao thông từ dữ liệu camera hành trình"là công trình nghiên cứu của riêng nhóm chúng tôi, được thực hiện dưới sự hướng dẫn khoa học của Thạc sĩ Huỳnh Lê Phú Trung.

Các số liệu, kết quả nghiên cứu và mã nguồn mô hình (YOLO, LSTM,...) được trình bày trong đồ án là trung thực và chưa từng được công bố trong bất kỳ công trình nào khác. Các thông tin tham khảo, tài liệu, hình ảnh và cơ sở lý thuyết trích dẫn từ các nghiên cứu trước đây đều được ghi rõ nguồn gốc trong danh mục tài liệu tham khảo.

Chúng tôi xin chịu hoàn toàn trách nhiệm về tính trung thực và bản quyền của đồ án này.

Họ và tên tác giả
Chữ ký

Phạm Phước Minh Hiếu

Cao Sỹ Siêu

LỜI CẢM ƠN

Để hoàn thành khóa luận tốt nghiệp này, tôi xin gửi lời tri ân sâu sắc nhất đến những người đã luôn hỗ trợ, động viên và hướng dẫn chúng tôi trong suốt quá trình nghiên cứu.

Trước hết, chúng tôi xin bày tỏ lòng biết ơn chân thành và sâu sắc nhất tới Thạc sĩ Huỳnh Lê Phú Trung. Thầy đã tận tình định hướng đề tài, chia sẻ những kiến thức quý báu về Trí tuệ nhân tạo và Thị giác máy tính, cũng như đưa ra những nhận xét khắt khe nhưng đầy tâm huyết giúp chúng tôi hoàn thiện phương pháp "Dự đoán ý định và phát hiện hành vi"trong điều kiện giao thông phức tạp.

Chúng tôi xin gửi lời cảm ơn đến Ban Giám hiệu và quý Thầy, Cô khoa Công nghệ. Những kiến thức nền tảng vững chắc mà quý Thầy Cô truyền đạt trong suốt những năm học qua chính là hành trang vô giá để tôi có thể thực hiện đồ án này.

Cuối cùng, chúng tôi xin cảm ơn gia đình, bạn bè đã luôn ở bên cạnh động viên tinh thần và hỗ trợ tôi trong những giai đoạn khó khăn nhất của quá trình thu thập dữ liệu và huấn luyện mô hình.

Mặc dù đã rất nỗ lực, nhưng do hạn chế về thời gian và kinh nghiệm thực tế, đồ án khó tránh khỏi những thiếu sót. Chúng tôi rất mong nhận được những ý kiến đóng góp quý báu của quý Thầy Cô và các bạn để đề tài được hoàn thiện và phát triển hơn nữa trong tương lai.

Chúng tôi xin chân thành cảm ơn!

Họ và tên tác giả
Chữ ký

Phạm Phước Minh Hiếu

Cao Sỹ Siêu

LỜI NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

Họ và tên sinh viên: Phạm Phước Minh Hiếu, Cao Sỹ Siêu
Ngành đào tạo: Công nghệ thông tin
Tên đề tài: Dự đoán ý định và phát hiện sớm hành vi chuyển làn cắt mặt của phương tiện tham gia giao thông từ dữ liệu camera hành trình

1. Nhận xét về nội dung và kết quả đạt được

. . . . . .
. . . . . .
. . . . . .
. . . . . .
. . . . . .
. . . . . .

2. Nhận xét về thái độ, ý thức và tinh thần làm việc của sinh viên

. . . . . .
. . . . . .
. . . . . .
. . . . . .
. . . . . .

3. Đánh giá chung

. . . . . .
. . . . . .
. . . . . .
. . . . . .

Kết luận:

☐ Đạt ☐ Không đạt

TP. Hồ Chí Minh, ngày ..... tháng ..... năm 20.....

Giảng viên hướng dẫn
(Ký và ghi rõ họ tên)

LỜI NHẬN XÉT CỦA GIẢNG VIÊN PHẢN BIỆN

Họ và tên sinh viên: Phạm Phước Minh Hiếu, Cao Sỹ Siêu
Ngành đào tạo: Công nghệ thông tin
Tên đề tài: Dự đoán ý định và phát hiện sớm hành vi chuyển làn cắt mặt của phương tiện tham gia giao thông từ dữ liệu camera hành trình

1. Nhận xét về nội dung và kết quả đạt được

. . . . . .
. . . . . .
. . . . . .
. . . . . .
. . . . . .
. . . . . .

2. Nhận xét về thái độ, ý thức và tinh thần làm việc của sinh viên

. . . . . .
. . . . . .
. . . . . .
. . . . . .
. . . . . .

3. Đánh giá chung

. . . . . .
. . . . . .
. . . . . .
. . . . . .

Kết luận:

☐ Đạt ☐ Không đạt

TP. Hồ Chí Minh, ngày ..... tháng ..... năm 20.....

Giảng viên phản biện
(Ký và ghi rõ họ tên)

Mục lục

Danh sách bảng

Danh sách hình vẽ

1 TÓM TẮT

Trong môi trường giao thông hỗn hợp, hành vi tạt đầu đột ngột của xe máy là một trong những nguyên nhân hàng đầu gây ra va chạm cho ô tô. Các hệ thống hỗ trợ lái xe (ADAS) hiện nay, thường dựa trên mô hình vật lý hoặc hồi quy quỹ đạo, gặp nhiều hạn chế về độ trễ và khả năng hội tụ khi đối mặt với các chuyển động phi tuyến tính phức tạp. Để giải quyết vấn đề này, đề tài đề xuất phương pháp phát hiện sớm dựa trên dự đoán ý định, chuyển đổi bài toán từ hồi quy tọa độ sang phân loại chuỗi thời gian với ba nhóm hành vi: giữ làn, tạt đầu và rẽ xa.

Kiến trúc hệ thống tích hợp mạng nơ-ron hồi quy (LSTM) để phân tích chuỗi đặc trưng logic hình học, đặc biệt khai thác sự biến thiên của tỷ lệ khung hình như một dấu hiệu sớm để nhận diện động tác nghiêng xe trước khi chuyển hướng. Bên cạnh đó, nghiên cứu thực hiện đánh giá so sánh thực nghiệm giữa các kiến trúc YOLO làm nền tảng nhận diện đầu vào [**?**, **?**]. Kết quả thực nghiệm cho thấy hướng tiếp cận phân loại ý định đạt độ tin cậy cao hơn đáng kể so với phương pháp hồi quy truyền thống trong bối cảnh dữ liệu nhiễu. Đồng thời, việc lựa chọn phiên bản YOLO tối ưu giúp hệ thống giảm thiểu độ trễ xử lý, đảm bảo khả năng cảnh báo sớm từ 1.5 đến 2 giây trên các thiết bị cấu hình giới hạn.

2 GIỚI THIỆU

2.1 Bối cảnh và Đặt vấn đề

Sự phát triển nhanh chóng của các hệ thống giao thông thông minh (ITS) và công nghệ xe tự hành đang đặt ra những yêu cầu khắt khe về khả năng nhận thức và dự đoán rủi ro. Mặc dù các hệ thống hỗ trợ lái xe (ADAS) hiện đại đã hoạt động hiệu quả trên đường cao tốc quy chuẩn, việc áp dụng chúng vào môi trường giao thông hỗn hợp vẫn gặp nhiều trở ngại [**?**]. Đặc thù tại các nước đang phát triển như Việt Nam là sự chiếm ưu thế tuyệt đối của xe máy (PTWs).

Khác với ô tô, xe máy có kích thước nhỏ, tính động lực học linh hoạt và thường xuyên di chuyển "phi làn đường". Trong dòng chảy giao thông hỗn loạn này, hành vi tạt đầu của xe máy là nguyên nhân hàng đầu gây ra va chạm, đòi hỏi hệ thống phải có khả năng phát hiện và cảnh báo ngay lập tức [**?**]. Tuy nhiên, để một hệ thống ADAS hoạt động hiệu quả trong bối cảnh này, nó phải giải quyết đồng thời hai bài toán khó: (1) Nhận diện vật thể chính xác với tốc độ cực nhanh và (2) Dự đoán hành vi phức tạp trước khi nó xảy ra.

2.2 Hạn chế của các phương pháp hiện hành

Về mặt dự đoán chuyển động, các phương pháp truyền thống dựa trên vật lý như Constant Velocity hay Constant Acceleration thường được sử dụng vì tính đơn giản [**?**]. Tuy nhiên, nhược điểm chí tử của nhóm phương pháp này là chúng chỉ hiệu quả trong ngắn hạn (dưới 1 giây) và không thể mô tả được các chuyển động phi tuyến tính. Khi xe máy thực hiện hành vi tạt đầu, các giả định vật lý ổn định bị phá vỡ, dẫn đến độ trễ lớn trong cảnh báo.

Về mặt nhận diện thị giác, các mô hình CNN truyền thống tuy có độ chính xác cao nhưng thường đòi hỏi tài nguyên tính toán lớn, khó triển khai trên các thiết bị camera hành trình nhỏ gọn. Sự thiếu hụt một cơ chế nhận diện tốc độ cao làm nền tảng đầu vào đã kìm hãm khả năng ứng dụng thực tế của các thuật toán dự đoán hành vi tiên tiến [**?**].

2.3 Tính cấp thiết và Giải pháp đề xuất

Để khắc phục các hạn chế trên, xu hướng nghiên cứu hiện đại đang chuyển dịch sang phương pháp dựa trên hành vi, tập trung nhận diện ý định của người lái thay vì chỉ hồi quy quỹ đạo đơn

thuần [?].

Các nghiên cứu tổng quan về Deep Learning khẳng định rằng mạng nơ-ron hồi quy, đặc biệt là LSTM có khả năng vượt trội trong việc học các đặc trưng chuỗi thời gian của hành vi lái xe [?].

Xuất phát từ thực tiễn đó, đề tài "Phát hiện sớm hành vi tạt đầu của xe máy trong giao thông hỗn hợp sử dụng dự đoán ý định dựa trên Camera hành trình"đề xuất một kiến trúc Hybrid Architecture. Hệ thống sử dụng mô hình YOLO làm nền tảng nhận thức thị giác cốt lõi để đảm bảo khả năng phát hiện và theo dõi xe máy theo thời gian thực với độ trễ thấp [?]. Dữ liệu từ YOLO sau đó được trích xuất thành các đặc trưng logic hình học để đưa vào mạng LSTM phân loại ý định. Sự kết hợp giữa tốc độ của YOLO và khả năng ghi nhớ chuỗi của LSTM kỳ vọng sẽ giải quyết được bài toán cảnh báo sớm trong môi trường giao thông phức tạp.

3 NGHIÊN CỨU LIÊN QUAN

3.1 Nhóm 1: Phương pháp dựa trên mô hình Vật lý và đặc trưng truyền thống

Nhóm phương pháp này tiếp cận bài toán dự đoán và nhận diện dựa trên các định luật vật lý rõ ràng hoặc các mô hình toán học được định nghĩa trước. Đặc điểm chung của nhóm này là tính minh bạch cao nhưng phụ thuộc lớn vào các giả định lý tưởng về môi trường và chuyển động.

Kinematic Models: Đây là nền tảng cổ điển nhất cho bài toán dự đoán quỹ đạo. Theo tổng quan của Paravarzar và Mohammad [?], các mô hình như Vận tốc không đổi (CV), Gia tốc không đổi (CA) đóng vai trò thiết yếu trong giai đoạn đầu của xe tự hành nhờ chi phí tính toán thấp. Các mô hình này thường kết hợp với Bộ lọc Kalman để ước lượng trạng thái tương lai. Điển hình cho hướng tiếp cận này là nghiên cứu của Lim và cộng sự [?] về hệ thống cảnh báo va chạm cho xe máy. Nhóm tác giả sử dụng bộ lọc Kalman lồng nhau để tính toán quỹ đạo và thời gian va chạm (TTC), chứng minh hiệu quả cao trong các tình huống xe di chuyển ổn định. Ngay cả trong các hệ thống hiện đại như DeepSORT, nghiên cứu của Kumar [?] cũng chỉ ra rằng bộ lọc Kalman vẫn là thành phần cốt lõi để duy trì định danh đối tượng dựa trên quán tính chuyển động khi việc nhận diện bị gián đoạn.

Mô hình dựa trên Đặc trưng Vật lý và thống kê: Bên cạnh động học, các phương pháp truyền thống còn khai thác các đặc trưng vật lý của tín hiệu và hình ảnh để nhận diện phương tiện. Ibarra Arenado [?] đã đề xuất sử dụng đặc tính quang học của bóng đổ (shadows) trên mặt đường để định vị chính xác vị trí tiếp xúc của bánh xe, giải quyết bài toán ước lượng khoảng cách trong thị giác máy tính đơn mắt. Tương tự, Coskun và Bilicz [?] khai thác đặc tính tán xạ vật lý của sóng radar (RCS) để phân loại phương tiện, cho thấy sự phụ thuộc chặt chẽ vào mô hình vật lý của tín hiệu phản xạ. Đối với các điều kiện môi trường khắc nghiệt, Pae và cộng sự [?] đã phát triển khung nhận diện dựa trên sự kết hợp các đặc trưng thủ công (HOG, LBP) để xử lý các biến thiên ánh sáng phức tạp. Ngoài ra, các kỹ thuật thống kê truyền thống như khoảng cách Mahalanobis cũng được Young và cộng sự [?] áp dụng để phát hiện các đối tượng ngoại lai dựa trên sự sai lệch so với phân phối nền chuẩn.

Hạn chế chung: Điểm yếu chí tử của nhóm phương pháp này là sự cứng nhắc. Các mô hình động học (Lim [?], Paravarzar [?]) thất bại khi xe máy thực hiện hành vi phi tuyến tính như "tạt đầu". Các mô hình dựa trên đặc trưng vật lý (Ibarra [?], Pae [?]) thường kém bền vững khi môi trường thay đổi quá nhanh (ví dụ: giao thông hỗn loạn tại Việt Nam) do các quy luật vật lý được định nghĩa thủ công không còn bao quát được hết các biến thể thực tế. Điều này thúc đẩy sự chuyển dịch sang các phương pháp học sâu có khả năng tự học các đặc trưng hành vi phức tạp hơn.

3.2 Nhóm 2: Phương pháp Hồi quy quỹ đạo

Khác với nhóm phương pháp vật lý, nhóm phương pháp Hồi quy Quỹ đạo tiếp cận bài toán dưới góc độ học sâu, coi việc dự đoán là một bài toán ánh xạ phi tuyến từ dữ liệu lịch sử sang chuỗi tọa độ liên tục (x, y) trong tương lai. Mục tiêu cốt lõi của nhóm này là cung cấp đầu vào chính xác cho các hệ thống điều khiển tự động.

Hồi quy dựa trên Mạng Nơ-ron Hồi quy (RNN/LSTM): Các nghiên cứu nền tảng thường sử dụng kiến trúc Encoder-Decoder với LSTM để nắm bắt sự phụ thuộc thời gian của chuỗi vị trí. Cao và cộng sự [**?**] đã áp dụng mô hình này để dự đoán xung đột giao thông tại các giao lộ, minh chứng cho khả năng học các mẫu di chuyển phức tạp mà mô hình vật lý bỏ qua. Đáng chú ý, Zarei và cộng sự [**?**] đã đề xuất một kiến trúc tích hợp chặt chẽ giữa nhận thức và dự đoán. Hệ thống sử dụng mạng YOLO cải tiến với module phân đoạn để định vị xe, sau đó đưa kết quả vào mạng đệ quy để hồi quy vị trí tiếp theo. Điểm sáng của nghiên cứu này là việc sử dụng thông tin phân loại hành vi lái xe để hỗ trợ quá trình hồi quy, giúp giảm sai số trong các tình huống chuyển làn.

Tiếp nối hướng tiếp cận lai, Wang và cộng sự [**?**] giới thiệu mạng F-Net, kết hợp CNN trích xuất đặc trưng hình ảnh không gian và LSTM xử lý dữ liệu hành trình thời gian. Wan và cộng sự [**?**] mở rộng tư duy này sang bài toán theo dõi đa đối tượng (MOT), sử dụng hồi quy bản đồ quỹ đạo để duy trì định danh đối tượng ổn định hơn.

Hồi quy có cấu trúc và Hướng mục tiêu (Structured & Target-driven): Để khắc phục nhược điểm tính toán trên dữ liệu pixel, Gao và cộng sự [**?**] đề xuất VectorNet, sử dụng Mạng nơ-ron đồ thị (GNN) để biểu diễn tương tác giữa các xe dưới dạng vector thưa. Trong khi đó, để giải quyết vấn đề đa hướng đi, Zhao và cộng sự [**?**] phát triển mô hình TNT, chia nhỏ bài toán thành dự đoán điểm đích trước khi hồi quy quỹ đạo chi tiết. Gần đây, Moon và cộng sự [**?**] còn tích hợp mô hình ngôn ngữ thị giác (VLM) để tận dụng các mô tả văn bản ngữ nghĩa trong việc định hướng quỹ đạo.

Vai trò và Hạn chế trong kịch bản Cut-in: Tầm quan trọng của hồi quy quỹ đạo được thể hiện rõ trong các hệ thống kiểm soát hành trình thích ứng (ACC). Chen và cộng sự [**?**] đã chứng minh rằng để một bộ điều khiển dự báo mô hình (MPC) xử lý an toàn tình huống xe tạt đầu, nó cần một chuỗi dự đoán quỹ đạo có độ chính xác cao làm đầu vào tối ưu hóa. Tuy nhiên, chính yêu cầu về "độ chính xác tọa độ"này lại là điểm yếu khi áp dụng vào bài toán cảnh báo sớm. Việc hồi quy chính xác vị trí (x, y) cho 3-5 giây tiếp theo đòi hỏi mô hình phải quan sát một chuỗi lịch sử đủ dài, gây ra độ trễ không mong muốn. Trong tình huống tạt đầu nguy hiểm, thông tin quan trọng nhất là "ý định"(ví dụ: xe đang lao vào làn) chứ không phải là tọa độ chính xác từng cm. Do đó, xu hướng nghiên cứu đang chuyển dịch sang bài toán Phân loại ý định để đạt được khả năng cảnh báo tức thời.

3.3 Nhóm 3: Phân loại Ý định và Nhận thức trong Giao thông Hỗn hợp

Khác với các phương pháp vật lý hay hồi quy quỹ đạo thuần túy, xu hướng nghiên cứu hiện đại chuyển dịch sang việc kết hợp nhận thức thị giác máy tính với phân loại hành vi để giải quyết bài toán độ trễ và độ phức tạp trong môi trường thực tế.

Đầu tiên, nền tảng của bài toán dự đoán là khả năng nhận diện vật thể chính xác và nhanh chóng trong môi trường giao thông hỗn hợp, nơi có mật độ phương tiện cao và đa dạng chủng loại. Giải quyết vấn đề này, Du và cộng sự [**?**] đã đề xuất phương pháp phát hiện chướng ngại vật thời gian thực dựa trên kiến trúc YOLO cải tiến (YOLOv4-tiny). Bằng cách thay thế hàm kích hoạt và tối ưu hóa anchor box bằng thuật toán K-means++, nghiên cứu đã chứng minh các mạng nơ-ron tích chập nhẹ hoàn toàn có thể đạt độ chính xác cao (mAP 80.39%) với tốc độ xử lý 22.5928 FPS ngay cả trong các điều kiện giao thông phức tạp. Kết quả này củng cố tính khả thi của việc sử dụng các mô hình họ YOLO làm tầng nhận thức đầu vào cho các hệ thống cảnh

báo sớm trên thiết bị biên.

Dựa trên dữ liệu nhận thức, bài toán tiếp theo là giải mã chuỗi hành vi để xác định ý định. Các phương pháp máy học truyền thống (như SVM, HMM) thường gặp khó khăn trong việc ghi nhớ các phụ thuộc dài hạn. Để khắc phục, He và các cộng sự [?] đã áp dụng mô hình Học sâu với mạng bộ nhớ ngắn hạn dài hạn hai chiều (Enhanced Bi-LSTM) kết hợp cơ chế chú ý. Nghiên cứu chỉ ra rằng việc mô hình hóa bài toán dưới dạng phân loại ý định, ví dụ như ý định chuyển làn sẽ giúp hệ thống đạt độ ổn định cao hơn so với hồi quy, với độ chính xác thực nghiệm lên tới 97.5% trên tập dữ liệu NGSIM. Điều này khẳng định vai trò chủ đạo của LSTM trong việc trích xuất đặc trưng thời gian từ chuỗi dữ liệu hành trình.

Cuối cùng, đối với kịch bản cụ thể là xe tạt đầu, việc định lượng rủi ro không chỉ dựa vào AI mà còn cần các ràng buộc hình học. Chen và cộng sự [?] đã phát triển thuật toán kiểm soát hành trình thích ứng cho tình huống cut-in dựa trên xác suất. Điểm đáng chú ý là họ sử dụng các đặc trưng logic như khoảng cách phương ngang và góc hướng di chuyển để tính toán xác suất xâm nhập làn đường. Cách tiếp cận này cho thấy việc kết hợp giữa dự đoán ý định và các tham số hình học (như dx, dy) là phương án tối ưu để phát hiện sớm các pha tạt đầu nguy hiểm trước khi va chạm xảy ra.

4 PHƯƠNG PHÁP NGHIÊN CỨU

4.1 Tổng quan Kiến trúc Hệ thống

Các phương pháp truyền thống trong dự đoán chuyển động thường tách biệt bài toán thành hai giai đoạn rời rạc: phát hiện vật thể và hồi quy quỹ đạo tương lai, như đã được tổng hợp trong các khảo sát của nhóm Lefèvre [?] và nhóm Mozaffari [?]. Tuy nhiên, trong môi trường giao thông hỗn hợp với mật độ cao, độ trễ tích lũy giữa các module này có thể làm giảm hiệu quả cảnh báo thời gian thực.

Để khắc phục hạn chế trên, nghiên cứu đề xuất kiến trúc End-to-End Risk Awareness. Hệ thống sử dụng một mạng nơ-ron tích chập sâu duy nhất để đồng thời thực hiện hai nhiệm vụ: định vị phương tiện và phân loại trực tiếp ý định hành vi dựa trên ngữ cảnh không gian, thay vì phụ thuộc vào các mô hình chuỗi thời gian phức tạp như LSTM hay GRU.

Quy trình xử lý gồm 3 giai đoạn chính:

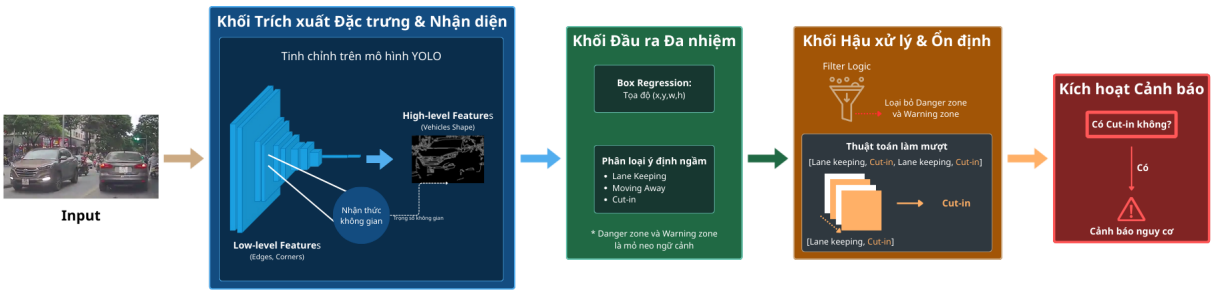

Hình 1: Sơ đồ tổng quan mô hình

1. Xây dựng Dữ liệu: Sử dụng quy trình bán tự động Human-in-the-loop.
2. Mô hình Nhận thức Hành vi: Sử dụng kiến trúc YOLO tinh chỉnh.
3. Hậu xử lý Thời gian thực: Ổn định tín hiệu cảnh báo.

4.2 Phương pháp Xây dựng Dữ liệu

Để giải quyết thách thức về khối lượng dữ liệu lớn và giảm thiểu chi phí nhân lực cho việc gán nhãn thủ công, đề tài đề xuất quy trình xử lý dữ liệu hai giai đoạn theo cơ chế "Human-in-the-loop"[**?**]. Cách tiếp cận này tận dụng một mô hình máy học sơ khởi (M_{assist}) để tự động đề xuất nhãn, chuyển vai trò của con người từ "người dán nhãn"sang "người kiểm định", đảm bảo nguyên tắc AI lấy con người làm trung tâm [**?**].

Quy trình tổng thể được mô tả tại Hình **??**, bao gồm hai giai đoạn chính:

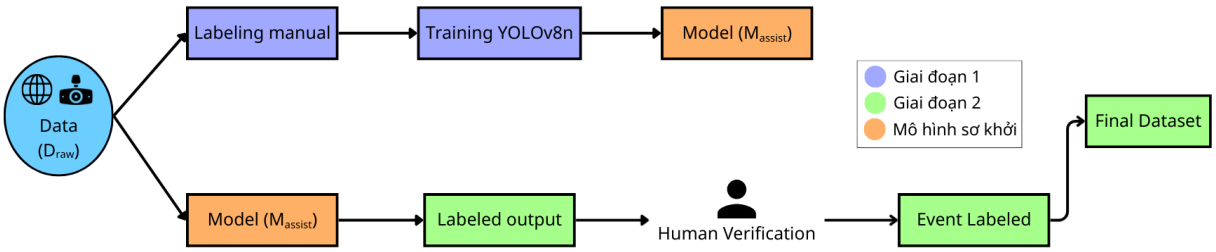

Hình 2: Sơ đồ tổng quan quy trình xây dựng dữ liệu hai giai đoạn

4.2.1 Giai đoạn 1: Thiết lập Mô hình Hỗ trợ (Bootstrap Phase)

Mục tiêu của giai đoạn này là giải quyết bài toán Cold Start bằng cách huấn luyện một mô hình sơ khởi từ tập dữ liệu hạt giống (D_{seed}).

Quy trình Tạo tập dữ liệu hạt giống (D_{seed}): Chúng tôi trích xuất ngẫu nhiên khoảng 10-15% tổng số lượng khung hình từ dữ liệu thô (D_{raw}). Các khung hình này được gán nhãn thủ công trên công cụ CVAT tuân thủ nghiêm ngặt các tiêu chuẩn sau:

- **Định nghĩa Lớp hành vi:** Xác định Bounding Box và phân loại hành vi động (`lane_keeping`, `moving_away`, `cut_in`) như Hình **??**.
- **Định nghĩa Vùng an toàn (Heuristic Approach):** Đối với các nhãn không gian tĩnh (`Danger Zone`, `Warning Zone`), thay vì áp dụng cứng nhắc các công thức khoảng cách tiêu chuẩn phương Tây (vốn gây ra cảnh báo rác trong điều kiện giao thông xe máy dày đặc tại Việt Nam), nghiên cứu thiết lập kích thước vùng dựa trên *kinh nghiệm thực tiễn*. Các đa giác được tinh chỉnh dựa trên quan sát góc nhìn thực tế của tài xế, đảm bảo phản ánh đúng không gian cần thiết cho hành vi phanh khẩn cấp trong giao thông nội đô.

Hình 3: Minh họa gán nhãn đối tượng

Cấu hình Mô hình M_{assist}: Mô hình được chọn là YOLOv8 (phiên bản nano) nhờ sự cân bằng giữa tốc độ và độ chính xác [**?**]. Chiến lược Transfer Learning từ trọng số COCO được áp dụng để tăng tốc độ hội tụ. Mục tiêu của M_{assist} là tối ưu hóa độ nhạy để hạn chế tối đa việc bỏ sót đối tượng (False Negative).

Tiêu chí Chuyển tiếp (Transition Criteria): Mô hình M_{assist} chỉ được chấp nhận đưa vào hỗ trợ Giai đoạn 2 khi đạt ngưỡng hiệu suất: mAP@50 $\geq$ 0.9. Ngưỡng này đảm bảo chất lượng gợi ý thị giác đủ tốt để giảm tải thao tác thủ công nhưng vẫn duy trì độ tin cậy [**?**].

4.2.2 Giai đoạn 2: Quy trình Gán nhãn Bán tự động (Semi-automated Labeling)

Sau khi đạt chuẩn, M_{assist} được áp dụng cho 85-90% dữ liệu còn lại theo quy trình:

1. **Tiền gán nhãn:** Mô hình sinh dự đoán bounding box và gán nhãn mặc định `lane_keeping` (lớp đa số) cho toàn bộ dữ liệu.
2. **Hiệu chỉnh:** Sử dụng CVAT để tinh chỉnh kích thước box và chỉ cần thay đổi nhãn sự kiện tại các thời điểm phát hiện hành vi bất thường (tạt đầu, rẽ), thay vì vẽ lại từ đầu.
3. **Đóng gói:** Dữ liệu sau hiệu chỉnh được hợp nhất và kiểm tra ngẫu nhiên lần cuối.

4.3 Mô hình Nhận thức Hành vi

Thay vì chỉ phát hiện lớp đối tượng chung là phương tiện, nghiên cứu tinh chỉnh mô hình YOLO để phân loại trực tiếp 3 trạng thái hành vi: Lane Keeping, Moving Away và Cut-in.

4.3.1 Lựa chọn Kiến trúc Mạng

Việc lựa chọn backbone phù hợp là yếu tố then chốt để đảm bảo khả năng vận hành thời gian thực trên thiết bị biên. Dựa trên phân tích so sánh chuyên sâu của Hidayatullah và cộng sự (2025) [**?**], nghiên cứu tiến hành thực nghiệm đối chiếu giữa hai biến thể:

- **YOLO26n**: Là một mô hình đầu cuối (end-to-end) hoàn toàn mới được thiết kế đặc biệt cho các thiết bị biên có công suất thấp. Kiến trúc này đơn giản hóa đường ống xử lý bằng cách loại bỏ hoàn toàn lớp hậu xử lý NMS và tối ưu hóa thuật toán MuSGD, giúp mô hình ổn định và hội tụ nhanh hơn [**?**].
- **YOLOv10n**: Là phiên bản YOLO cải tiến dựa trên nền tảng YOLOv8, được tối ưu cho phát hiện đối tượng thời gian thực với kiến trúc gọn hơn, cơ chế huấn luyện mới loại bỏ NMS và đem lại hiệu năng tốt trong nhiều kịch bản triển khai [**?**].

Để minh chứng cụ thể sự tối ưu về mặt tài nguyên, Bảng **??** trình bày sự so sánh giữa hai kiến trúc này (phiên bản kích thước Nano) trên bộ dữ liệu chuẩn COCO.

Dựa trên số liệu từ Bảng **??**, có thể thấy YOLO26n thể hiện sự vượt trội so với nền tảng YOLOv10n:

- **Về độ chính xác:** YOLO26n đạt hiệu suất cao hơn đáng kể (40.9% mAP). Khả năng trích xuất đặc trưng tốt giúp mô hình nhạy bén trong việc phát hiện từ sớm các dấu hiệu tinh vi của phương tiện, chẳng hạn như sự thay đổi góc nghiêng của xe máy khi bắt đầu có ý định tạt đầu.
- **Về chi phí tính toán:** Mặc dù khối lượng tham số của hai mô hình là gần tương đương nhau (khoảng 2.3 - 2.4 triệu), YOLO26n lại tối ưu hóa phép toán cực kỳ ấn tượng, giảm FLOPs xuống chỉ còn 5.4B (so với 6.7B của v10n). Điều này giúp tiết kiệm năng lượng tiêu thụ, giảm nhiệt độ tỏa ra và duy trì độ trễ xử lý cực thấp trên các vi mạch nhúng.

Bảng 1: So sánh thông số kỹ thuật các biến thể YOLO (Phiên bản Nano) trên độ phân giải 640×640.

Model	$\mathbf{mAP}^{val}_{50-95}$	**Tham số (M)**	**FLOPs (B)**	**Năm**
YOLO26n	**40.9**	2.4	**5.4**	2026
YOLOv10n	39.5	**2.3**	6.7	2024

**Ghi chú: Số liệu Inference đo trên T4 GPU (TensorRT FP16) theo công bố của Ultralytics.*

Do đó, nghiên cứu quyết định lựa chọn **YOLO26n** làm kiến trúc mạng trọng tâm để phát triển và triển khai hệ thống nhận diện rủi ro, đồng thời sử dụng YOLOv10n làm mô hình cơ sở đối chứng trong quá trình thực nghiệm.

4.3.2 Cơ chế Huấn luyện

Để tối ưu hóa hiệu năng của kiến trúc YOLO26n trong bài toán nhận diện ý định và hành vi phương tiện, quá trình huấn luyện được thiết lập một cách nghiêm ngặt với các kỹ thuật tinh chỉnh tham số và tăng cường dữ liệu tiên tiến.

1. Môi trường và Thiết lập cơ sở: Quá trình thực nghiệm được triển khai trên máy chủ đám mây với bộ xử lý đồ họa GPU NVIDIA Tesla T4 (16GB VRAM) nhằm đáp ứng nhu cầu tính toán hiệu năng cao. Mô hình được khởi tạo theo chiến lược Học chuyển giao, sử dụng tập trọng số đào tạo trước để tận dụng khả năng trích xuất đặc trưng chung, từ đó rút ngắn thời gian hội tụ trên tập dữ liệu giao thông nội bộ. Tập dữ liệu cấu thành gồm 17.939 khung ảnh huấn luyện và 3.611 khung ảnh kiểm chứng.

2. Cấu hình Siêu tham số: Các tham số cấu hình cốt lõi được lựa chọn thông qua quá trình thử nghiệm lặp nhằm cân bằng giữa tốc độ học và sự ổn định:

- **Kích thước đầu vào:** Ảnh được chuẩn hóa về độ phân giải 640×640 pixel. Đây là kích thước tối ưu (sweet-spot) của các mạng YOLO, vừa giữ được chi tiết của vật thể nhỏ ở xa (dấu hiệu chuyển làn), vừa không làm quá tải bộ nhớ.
- **Kích thước lô:** Đặt ở mức 16, phù hợp với dung lượng bộ nhớ của GPU Tesla T4 và đảm bảo gradient được cập nhật mượt mà.
- **Số kỷ nguyên & Dừng sớm:** Mô hình được thiết lập huấn luyện tối đa 100 epochs. Để ngăn chặn hiện tượng học vẹt, cơ chế *Early Stopping* được áp dụng với `patience=8` (tự động dừng nếu mô hình không cải thiện sau 8 kỷ nguyên liên tiếp).

3. Thuật toán Tối ưu hóa: Điểm sáng công nghệ lớn nhất trong cơ chế huấn luyện của YOLO26 là việc ứng dụng bộ tối ưu hóa lai **MuSGD** (kết hợp giữa nguyên lý phân kỳ SGD và bộ tối ưu hóa Muon). Lấy cảm hứng từ những đột phá trong huấn luyện Mô hình ngôn ngữ lớn (LLM - tiêu biểu là kiến trúc Kimi K2 của Moonshot AI) [**?**], việc chuyển giao MuSGD vào lĩnh vực thị giác máy tính giúp mô hình đạt được sự ổn định nâng cao và tốc độ hội tụ nhanh hơn hẳn so với các thuật toán truyền thống. Bộ tối ưu hóa được cấu hình với tốc độ học khởi tạo (lr_0) là 0.01 và hệ số quán tính là 0.9.

4. Tinh chỉnh Kiến trúc và Hàm mất mát: Kiến trúc của mạng được tinh gọn hóa thông qua các cải tiến mang tính chiến lược, đặc biệt phù hợp cho các hệ thống ADAS bị hạn chế về tài nguyên phần cứng:

- **Loại bỏ NMS và DFL:** YOLO26 là một mô hình đầu cuối tích hợp (end-to-end inference), dự đoán trực tiếp Bounding Box mà không cần bước hậu xử lý triệt tiêu cực đại (NMS). Đồng thời, mô-đun Distribution Focal Loss (DFL) cũng được loại bỏ hoàn toàn nhằm đơn giản hóa quá trình xuất (export) và tăng khả năng tương thích với các thiết bị biên (edge devices) [**?**].
- **Tích hợp ProgLoss và STAL:** Các hàm mất mát mới này được áp dụng nhằm tăng cường đáng kể độ chính xác khi nhận dạng các vật thể nhỏ. Trong ngữ cảnh bài toán tạt đầu, điều này đóng vai trò then chốt giúp mạng nhạy bén hơn trong việc trích xuất các đặc trưng tinh vi như sự thay đổi nhỏ về góc nghiêng của phương tiện [**?**].

5. Tăng cường Dữ liệu: Để gia tăng tính bền vững, pipeline huấn luyện tích hợp thư viện Albumentations:

- **Biến đổi quang học:** Cân bằng sáng CLAHE, làm mờ, chuyển ảnh xám với tỷ lệ nhỏ nhằm giúp mô hình thích ứng với sự thay đổi thời tiết, ánh sáng chói hoặc sương mù.
- **Biến đổi không gian:** Áp dụng lật ngang ảnh (`fliplr=0.5`), dịch chuyển (`translate=0.1`), và thay đổi tỷ lệ (`scale=0.5`).

4.4 Hậu xử lý & Ổn định Cảnh báo

Mặc dù mô hình YOLO26n cung cấp tốc độ nhận diện vượt trội, các dự đoán thô (raw predictions) từ mạng nơ-ron thường xuyên gặp hiện tượng nhiễu tín hiệu (jittering) – trạng thái nhãn thay đổi liên tục giữa các khung hình do nhiễu môi trường hoặc vật thể bị che khuất tạm thời. Để hệ thống có thể đưa ra cảnh báo tin cậy cho tài xế, chúng tôi triển khai quy trình hậu xử lý hai tầng.

4.4.1 Cơ chế Ổn định Nhãn

Thay vì đưa ra cảnh báo ngay lập tức dựa trên kết quả của một khung hình đơn lẻ, hệ thống sử dụng một cửa sổ trượt thời gian (sliding window) kích thước W để theo dõi lịch sử trạng thái của từng phương tiện.

Gọi L_t là nhãn dự đoán của phương tiện tại thời điểm t. Trạng thái cuối cùng S_{final} được xác định thông qua bộ lọc đa số (Majority Voting):

$$S_{final} = mode\{L_{t-W}, \ldots, L_t\} \tag{1}$$

Trong thực nghiệm, chúng tôi thiết lập $W = 5$ khung hình. Cơ chế này giúp loại bỏ các dự đoán sai lệch ngắn hạn, đảm bảo tín hiệu cảnh báo chỉ được kích hoạt khi hành vi `cut_in` được xác nhận ổn định trong một khoảng thời gian đủ lớn.

4.4.2 Logic Cảnh báo Đa tầng dựa trên Vùng Không gian

Hệ thống tích hợp kết quả phân loại hành vi với các vùng an toàn đã thiết lập bằng phương pháp Heuristic để định lượng mức độ rủi ro. Logic cảnh báo được phân cấp như sau:

- **Cấp độ 1 (Theo dõi - Monitoring):** Phương tiện được nhãn `lane_keeping` hoặc `moving_away`, nằm ngoài các vùng an toàn. Hệ thống duy trì trạng thái theo dõi bình thường.

- **Cấp độ 2 (Chú ý - Attention):** Phương tiện nằm trong `Warning Zone` và bắt đầu có nhãn `cut_in`. Hệ thống chuẩn bị các tham số tính toán nhưng chưa phát tín hiệu âm thanh để tránh gây xao nhãng cho tài xế.
- **Cấp độ 3 (Cảnh báo - Warning):** Phương tiện nằm trong `Danger Zone` đồng thời được xác nhận nhãn `cut_in`. Tại đây, hệ thống kích hoạt cảnh báo thị giác và âm thanh ngay lập tức.

4.4.3 Ước tính Độ nguy hiểm dựa trên Tỷ lệ Khung hình

Để hỗ trợ thêm cho việc phát hiện sớm ý định, hệ thống theo dõi biến thiên tỷ lệ khung hình (Aspect Ratio - AR) của Bounding Box. Khi xe máy chuẩn bị tạt đầu, động tác nghiêng xe và hướng di chuyển chéo làm thay đổi giá trị AR một cách đặc trưng trước khi tọa độ trung tâm thay đổi lớn.

$$\Delta AR = \frac{W_t}{H_t} - \frac{W_{t-1}}{H_{t-1}} \tag{2}$$

Sự kết hợp giữa nhãn từ mô hình YOLO26n và xu hướng biến thiên ΔAR cho phép hệ thống "nhìn trước"được hành vi tạt đầu từ 0.5 đến 1 giây so với các phương pháp dựa trên khoảng cách thuần túy, giúp bù đắp độ trễ phản xạ của tài xế trong các tình huống khẩn cấp.

5 KẾT QUẢ NGHIÊN CỨU

5.1 Kết quả Huấn luyện Mô hình Hỗ trợ

Dựa trên phương pháp luận đã đề xuất, mô hình sơ khởi (M_{assist}) đã được huấn luyện trên tập dữ liệu hạt giống D_{seed}. Kết quả thực nghiệm cho thấy mô hình đáp ứng tốt các tiêu chí chuyển tiếp để phục vụ quy trình bán tự động.

5.1.1 Sự hội tụ của mô hình

Để đánh giá chi tiết hành vi học tập của mô hình hỗ trợ M_{assist} qua 40 epochs, nghiên cứu thực hiện đối chiếu các thành phần Loss giữa tập train và tập val.

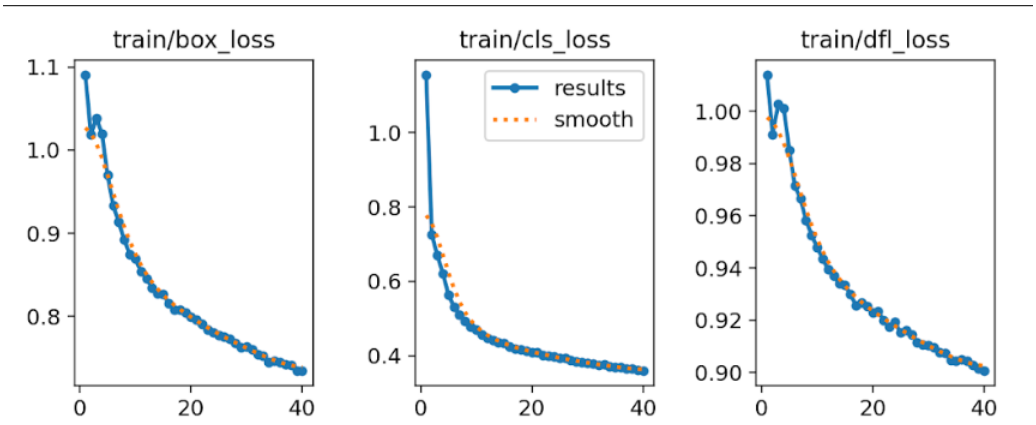

Hình 4: Các chỉ số hàm mất mát trên tập huấn luyện

Dựa trên kết quả thực nghiệm thu được từ quá trình huấn luyện mô hình M_{assist}:

- **train/box_loss:** Chỉ số này thể hiện sai số trong việc dự đoán tọa độ của **Bounding Box**. Đồ thị cho thấy xu hướng giảm ổn định từ mức 1.1 xuống còn 0.73, chứng minh thuật toán đang tối ưu tốt khả năng định vị phương tiện qua từng vòng lặp.

- **train/cls_loss:** Đây là chỉ số đánh giá độ chính xác của việc phân loại các lớp hành vi. Đồ thị giảm mạnh ngay từ những **epochs** đầu tiên và tiệm cận mức 0.35, khẳng định mô hình nhận diện rất tốt các đặc trưng của 3 nhóm trạng thái: `lane_keeping`, `moving_away` và `cut_in`.

- **train/dfl_loss:** Chỉ số **Distribution Focal Loss** giúp mô hình học cách phân phối xác suất của các giá trị tọa độ xung quanh biên của vật thể. Đồ thị hội tụ về mức 0.90; việc giảm dần của **DFL** hỗ trợ mô hình tinh chỉnh các biên của vật thể một cách mượt mà, đặc biệt hiệu quả trong việc xử lý các đối tượng xe máy có kích thước nhỏ.

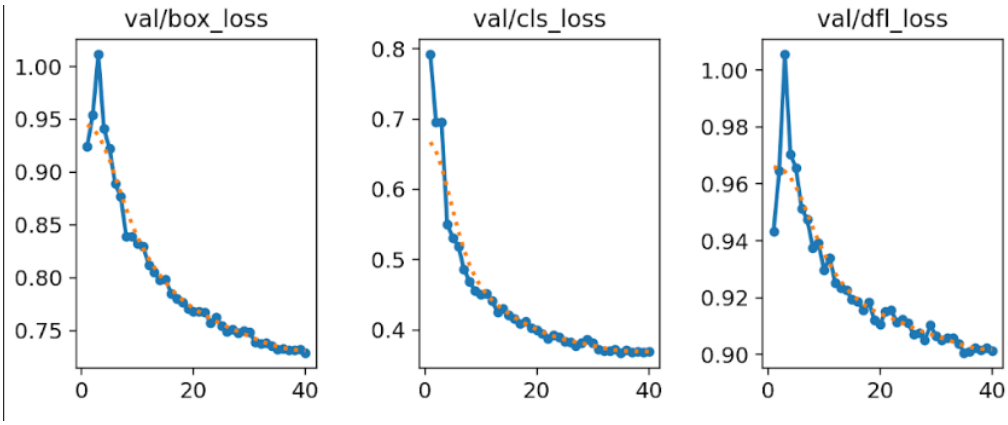

Hình 5: Các chỉ số hàm mất mát trên tập kiểm định

Quá trình đánh giá hiệu suất trên tập kiểm định cho thấy các đặc tính sau:

- **val/box_loss & val/dfl_loss:** Mặc dù xuất hiện một số điểm biến động (**spikes**) tại giai đoạn đầu (khoảng **epoch** thứ 3 đến thứ 5), nhưng ngay sau đó cả hai chỉ số đều duy trì xu hướng giảm tương đồng với tập **train**. Các biến động này thường do sự điều chỉnh trọng số của bộ tối ưu hóa khi tiếp cận các mẫu dữ liệu khó trong tập kiểm định.

- **val/cls_loss:** Đồ thị đạt mức ổn định khoảng 0.38 và duy trì trạng thái nằm ngang ở các **epochs** cuối. Điều quan trọng là chỉ số này không có dấu hiệu tăng ngược lại, minh chứng cho việc mô hình không bị rơi vào hiện tượng **overfitting**.

Sự hội tụ đồng nhất giữa **Training Loss** và **Validation Loss** với khoảng cách sai số nhỏ khẳng định mô hình M_{assist} đạt độ tin cậy cao và khả năng **generalization** tốt. Đây là tiền đề vững chắc để đưa mô hình vào vận hành cho quy trình gán nhãn bán tự động ở Giai đoạn 2.

5.1.2 Hiệu suất Mô hình trên Tập kiểm định

Biểu đồ quá trình huấn luyện (Hình **??**) cho thấy sự hội tụ ổn định của mô hình. Chỉ số độ chính xác trung bình (mAP@50) đạt mức cao xấp xỉ **0.97**, vượt qua ngưỡng yêu cầu 0.9 đã thiết lập tại phần Phương pháp.

Điều này chứng minh rằng chiến lược sử dụng YOLOv8n kết hợp Transfer Learning đã phát huy hiệu quả trong việc học nhanh các đặc trưng từ tập dữ liệu nhỏ ban đầu, tạo tiền đề vững chắc cho việc gán nhãn tự động quy mô lớn.

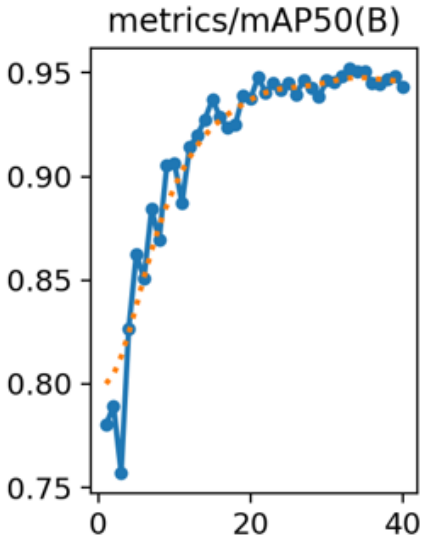

Hình 6: Biểu đồ mAP@50 của mô hình M_{assist} qua các epoch

5.1.3 Phân tích Ma trận Nhầm lẫn (Confusion Matrix)

Khả năng phân loại chi tiết của M_{assist} được thể hiện qua ma trận nhầm lẫn tại Hình **??**.

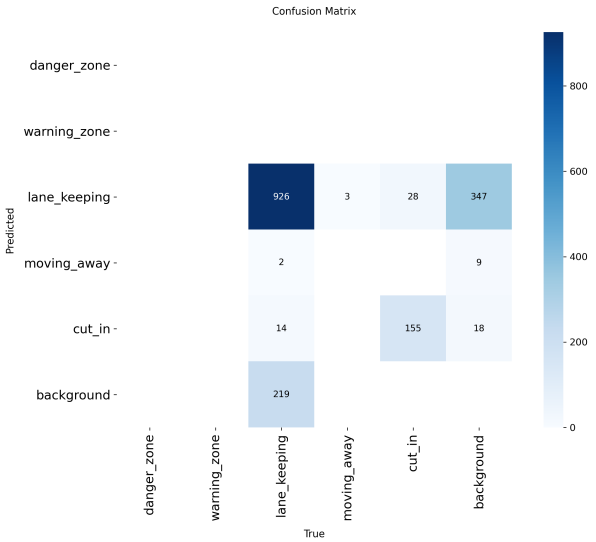

Hình 7: Ma trận nhầm lẫn của mô hình sơ khởi M_{assist}

Kết quả cho thấy:

- Tỷ lệ nhận diện đúng (True Positive) của các lớp quan trọng như `cut_in` và `lane_keeping` đạt mức cao.
- Sự nhầm lẫn giữa các vùng tĩnh (`Danger Zone` vs `Warning Zone`) nằm trong mức chấp nhận được đối với một mô hình sơ khởi.
- Tỷ lệ bỏ sót đối tượng (Background FN) rất thấp, thỏa mãn yêu cầu về tối ưu hóa độ nhạy (Recall) để hỗ trợ người kiểm định không bị sót xe trong khung hình.

Kết luận: Với các chỉ số hiệu năng trên, mô hình M_{assist} chính thức được đưa vào vận hành cho Giai đoạn 2, giúp giảm thiểu đáng kể thời gian gán nhãn cho phần dữ liệu thô còn lại.

5.2 Kết quả thực nghiệm mô hình trọng tâm

Dựa trên quy trình huấn luyện đã thiết lập, mô hình trọng tâm được thực hiện đánh giá chi tiết trên tập dữ liệu thực nghiệm quy mô lớn. Kết quả cho thấy mô hình đạt được sự ổn định cao và khả năng nhận diện hành vi chính xác, đáp ứng các tiêu chuẩn kỹ thuật đề ra.

5.2.1 Sự hội tụ của mô hình

Để đánh giá chi tiết hành vi học tập của mô hình trọng tâm qua 65 **epochs**, nghiên cứu thực hiện đối chiếu các thành phần **Loss** giữa tập **train** và tập **val**.

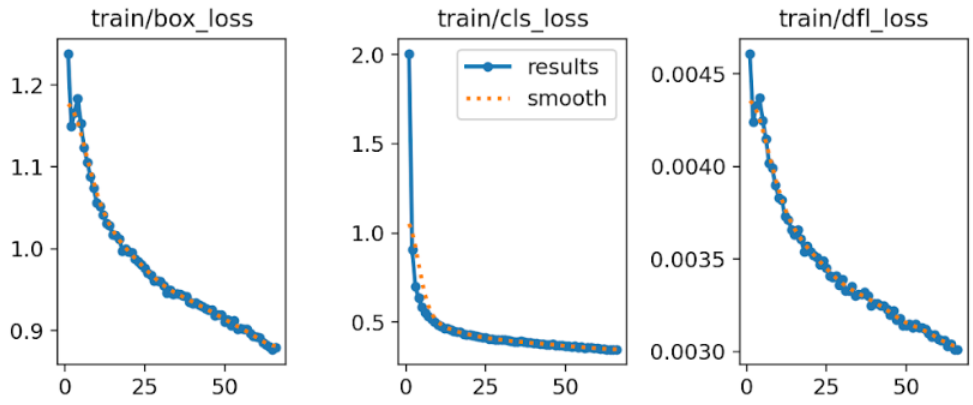

Hình 8: Các chỉ số hàm mất mát trên tập huấn luyện của mô hình trọng tâm

Dựa trên kết quả thu được từ quá trình huấn luyện:

- **train/box_loss**: Chỉ số này thể hiện sai số trong việc dự đoán tọa độ của **Bounding Box**. Đồ thị cho thấy xu hướng giảm ổn định từ mức 1.25 xuống còn 0.88. Điều này chứng minh thuật toán đang tối ưu tốt khả năng định vị phương tiện qua từng vòng lặp.
- **train/cls_loss**: Đây là chỉ số đánh giá độ chính xác của việc phân loại các lớp hành vi. Đồ thị giảm mạnh ngay từ những **epochs** đầu tiên từ mức 2.0 xuống tiệm cận mức 0.35. Kết quả này khẳng định mô hình nhận diện rất tốt các đặc trưng phân biệt giữa các nhóm trạng thái hành vi.
- **train/dfl_loss**: Hội tụ mượt mà về mức 0.003. Việc giảm dần của **DFL** hỗ trợ mô hình tinh chỉnh các biên của vật thể một cách chính xác, giúp xử lý tốt các đối tượng có kích thước nhỏ như xe máy.

Quá trình đánh giá hiệu suất trên tập kiểm định (**Validation**) cho thấy các đặc tính sau:

- **val/box_loss & val/dfl_loss**: Mặc dù xuất hiện một số điểm biến động (**spikes**) tại giai đoạn đầu (khoảng **epoch** thứ 3 đến thứ 10), nhưng ngay sau đó cả hai chỉ số đều duy trì xu hướng giảm tương đồng với tập **train** và ổn định dần về cuối quá trình.
- **val/cls_loss**: Đồ thị đạt mức ổn định khoảng 0.4 và duy trì trạng thái nằm ngang ở các **epochs** cuối. Điều quan trọng là chỉ số này không có dấu hiệu tăng ngược lại, minh chứng cho việc mô hình không bị rơi vào hiện tượng **overfitting**.

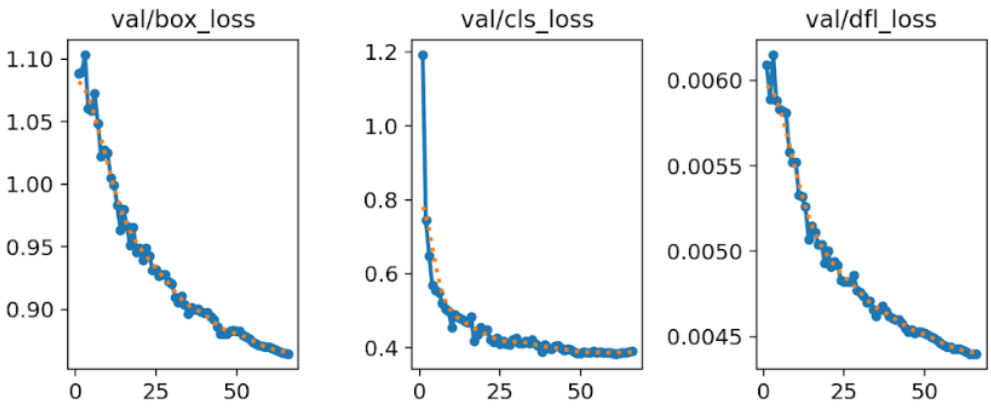

Hình 9: Các chỉ số hàm mất mát trên tập kiểm định của mô hình trọng tâm

5.2.2 Hiệu suất mô hình trên tập kiểm định

Chỉ số độ chính xác trung bình (**mAP@50**) đóng vai trò quyết định trong việc đánh giá năng lực thực tế của mô hình được thể hiện tại Hình **??**.

Biểu đồ quá trình huấn luyện tại Hình **??** cho thấy sự hội tụ ấn tượng của mô hình. Chỉ số **mAP@50** tăng trưởng mạnh mẽ từ mức ban đầu 0.53 và đạt ngưỡng ổn định xấp xỉ **0.80** sau 50 **epochs** huấn luyện. Điều này chứng minh mô hình trọng tâm đã đạt được độ tin cậy cao trong việc nhận diện đối tượng và hành vi trên tập dữ liệu thực nghiệm quy mô lớn.

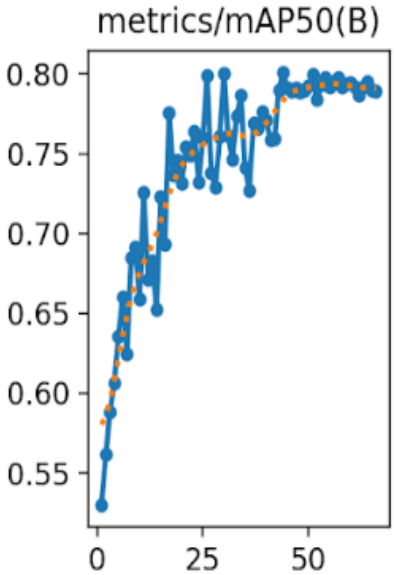

Hình 10: Biểu đồ mAP@50 của mô hình trọng tâm qua các epoch

5.2.3 Phân tích Ma trận Nhầm lẫn (Confusion Matrix)

Khả năng phân loại chi tiết của mô hình trọng tâm được minh chứng qua ma trận nhầm lẫn thực nghiệm tại Hình **??**.

Dựa trên số liệu thống kê từ ma trận nhầm lẫn:

- **Độ chính xác phân loại hành vi**: Mô hình đạt tỷ lệ nhận diện đúng (**True Positive**) cực cao đối với lớp `lane_keeping` với 9932 mẫu và lớp hành vi tạt đầu `cut_in` với 1146 mẫu được phân loại chính xác.

- **Tỷ lệ bỏ sót (Background FN)**: Đối với lớp hành vi quan trọng `cut_in`, chỉ có 86 trường hợp bị nhầm lẫn thành nền (**background**), đảm bảo hệ thống duy trì tính an toàn cao và không bỏ qua các kịch bản tạt đầu nguy hiểm.
- **Phân loại vùng không gian**: Các vùng tĩnh được mô hình phân loại với độ chính xác tuyệt đối, hỗ trợ tốt cho các thuật toán hậu xử lý tính toán mức độ rủi ro dựa trên vị trí phương tiện trong các vùng an toàn.

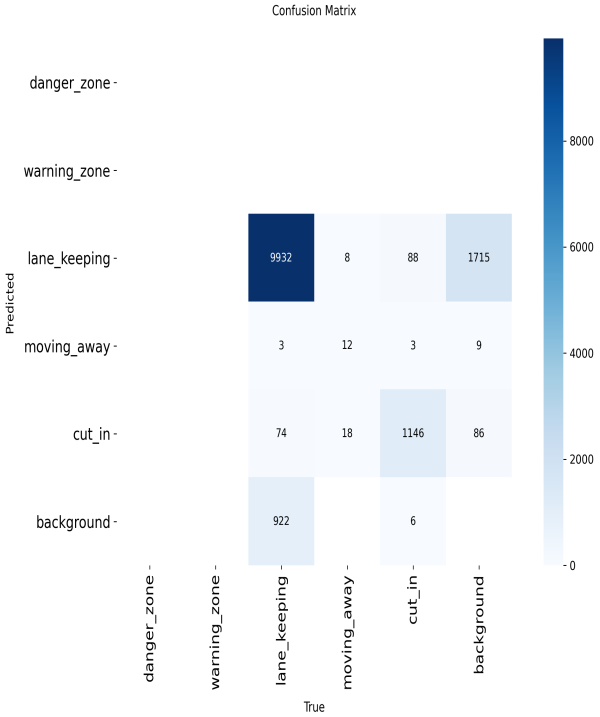

Hình 11: Ma trận nhầm lẫn của mô hình trọng tâm

Kết luận: Với sự hội tụ đồng nhất giữa các chỉ số **Loss** và sự gia tăng ổn định của **mAP@50**, mô hình trọng tâm đã chứng minh được năng lực nhận thức hành vi vượt trội. Kết quả thực nghiệm khẳng định tính khả thi của việc triển khai mô hình vào hệ thống dự đoán ý định và cảnh báo sớm hành vi tạt đầu trong giao thông thực tế.

6 KẾT LUẬN & HƯỚNG PHÁT TRIỂN

6.1 Hạn chế của nghiên cứu

Mặc dù hệ thống đã đạt được độ chính xác cao trong việc nhận diện hành vi tạt đầu, một hạn chế của nghiên cứu là việc định cỡ các vùng an toàn (Polygon zones) vẫn đang phụ thuộc vào góc nhìn camera cố định. Do không sử dụng cảm biến chiều sâu (LiDAR/Radar), nghiên cứu này mang tính chất một Proof of Concept (PoC), tập trung vào việc chứng minh năng lực của kiến trúc YOLO kết hợp Reinforcement Learning trong bài toán nhận diện ý định. Trong các phiên bản triển khai thực tế tiếp theo, hệ thống có thể tích hợp thêm module tự động hiệu chuẩn (Auto-calibration) dựa trên phép chiếu IPM để vùng đa giác tự động thích ứng với nhiều loại camera và độ cao lắp đặt khác nhau.

6.2 Hướng phát triển tương lai

7 DANH MỤC TÀI LIỆU TRÍCH DẪN

[1] P. Hidayatullah, N. Syakrani, M. R. Sholahuddin, T. Gelar, and R. Tubagus, "Yolov8 to yolo11: A comprehensive architecture in-depth comparative review," *ArXiv*, vol. abs/2501.13400, 2025.

[2] W. Lv, S. Xu, Y. Zhao, G. Wang, J. Wei, C. Cui, Y. Du, Q. Dang, and Y. Liu, "Detrs beat yolos on real-time object detection," *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 16965–16974, 2023.

[3] S. Lefèvre, D. Vasquez, and C. Laugier, "A survey on motion prediction and risk assessment for intelligent vehicles," *ROBOMECH Journal*, vol. 1, 2014.

[4] L. Zeng, F. Chen, J. Li, H. Wang, Y. Li, and Z. Zhai, "Trajectory prediction for powered two-wheelers in mixed traffic scenes: An enhanced social-gat approach," *Systems*, 2025.

[5] S. Mozaffari, O. Y. Al-Jarrah, M. Dianati, P. Jennings, and A. Mouzakitis, "Deep learning-based vehicle behavior prediction for autonomous driving applications: A review," *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, pp. 33–47, 2020.

[6] S. Paravarzar and B. Mohammad, "Motion prediction on self-driving cars: A review," *arXiv preprint arXiv:2011.03635*, 2020.

[7] Q. Lim, Y. Lim, H. s. Muhammad, D. W. M. Tan, and U.-X. Tan, "Forward collision warning system for motorcyclist using smart phone sensors based on time-to-collision and trajectory prediction," *Journal of Engineering*, 2018.

[8] S. Kumar, S. K. Singh, S. Varshney, S. Singh, P. Kumar, B.-G. Kim, and I.-H. Ra, "Fusion of deep sort and yolov5 for effective vehicle detection and tracking scheme in real-time traffic management sustainable system," *Sustainability*, vol. 15, no. 24, p. 16869, 2023.

[9] M. Ibarra Arenado, *Detección y localización de vehículos mediante sombras en la carretera basada en visión por computador.* PhD thesis, Universidad de Cantabria, 2016.

[10] A. Coşkun and S. Bilicz, "Data-driven clustering and classification of road vehicle radar scattering characteristics using histogram-based rcs features," *Electronics*, vol. 13, no. 4, p. 759, 2024.

[11] D. S. Pae, I. H. Choi, T. K. Kang, and M. T. Lim, "Vehicle detection framework for challenging lighting driving environment based on feature fusion method using adaptive neuro-fuzzy inference system," *International Journal of Advanced Robotic Systems*, vol. 15, no. 2, 2018.

[12] A. Young, S. Marshall, and A. Gray, "Outlier and target detection in aerial hyperspectral imagery: A comparison of traditional and percentage occupancy hit or miss transform techniques," in *Target and Background Signatures II*, vol. 10000, SPIE, 2016.

[13] Q. Cao, Z. Zhao, Q. Zeng, Z. Wang, and K. Long, "Real-time vehicle trajectory prediction for traffic conflict detection at unsignalized intersections," *Journal of Advanced Transportation*, vol. 2021, pp. 1–15, 2021.

[14] N. Zarei, P. Moallem, and M. Shams, "Real-time vehicle detection using segmentation-based detection network and trajectory prediction," *IET Computer Vision*, vol. 17, no. 2, pp. 207–220, 2023.

[15] J. Wang, P. Wang, C. Zhang, K. Su, and J. Li, "Fusion neural network for vehicle trajectory prediction in autonomous driving," in *ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2021.

[16] X. Wan, S. Zhou, J. Wang, and R. Meng, "Multiple object tracking by trajectory map regression with temporal priors embedding," in *Proceedings of the 29th ACM International Conference on Multimedia*, pp. 1–9, 2021.

[17] J. Gao, C. Sun, H. Zhao, Y. Shen, D. Anguelov, C. Li, and C. Schmid, "Vectornet: Encoding hd maps and agent dynamics from vectorized representation," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2020.

[18] H. Zhao, J. Gao, T. Lan, C. Sun, and B. Sapp, "Tnt: Target-driven trajectory prediction," in *Conference on Robot Learning (CoRL)*, 2020.

[19] S. Moon, H. Woo, H. Park, H. Jung, *et al.*, "Visiontrap: Vision-augmented trajectory prediction guided by textual descriptions," *arXiv preprint arXiv:2407.12345*, 2024.

[20] C. Chen, J. Guo, C. f. Guo, C. Chen, Y. Zhang, and J. Wang, "Adaptive cruise control for cut-in scenarios based on model predictive control algorithm," *Applied Sciences*, vol. 11, no. 11, p. 5293, 2021.

[21] L. Du, X. Chen, Z. Pei, D. Zhang, B. Liu, and W. Chen, "Improved real-time traffic obstacle detection and classification method applied in intelligent and connected vehicles in mixed traffic environment," *Journal of Advanced Transportation*, 2022.

[22] D. He, M. Zhao, and Z. Wang, "Vehicle driving intent recognition based on enhanced bidirectional long short-term memory network," *Journal of Artificial Intelligence Practice*, 2023.

[23] C. Chen, J. Guo, C. Guo, C. Chen, Y. Zhang, and J. Wang, "Adaptive cruise control for cut-in scenarios based on model predictive control algorithm," *Applied Sciences*, 2021.

[24] S. Branson, C. Wah, F. Schroff, B. Babenko, P. Welinder, P. Perona, and S. J. Belongie, "Visual recognition with humans in the loop," in *European Conference on Computer Vision*, 2010.

[25] B. Shneiderman, "Human-centered artificial intelligence: Reliable, safe & trustworthy," *International Journal of Human–Computer Interaction*, vol. 36, pp. 495 – 504, 2020.

[26] G. Jocher and J. Qiu, "Ultralytics yolo26," 2026. Version 26.0.0.

8 DANH MỤC TÀI LIỆU THAM KHẢO

[1] Ultralytics GitHub repository: https://github.com/ultralytics/ultralytics

[2] A. Wang, H. Chen, L. Liu *et al.*, "YOLOv10: Real-Time End-to-End Object Detection," *arXiv preprint arXiv:2405.14458*, 2024.